UNIVERSIDAD POLITÉCNICA DE ATLAUTLA

MATERIA: Fundamentos de Inteligencia Artificial

DOCENTE: Mtro. Javier García Lara

ALUMNA: Denise Estrada Franco

TEMA: 1.7 Aplicaciones y casos de estudio de IA

SEMANA 1: 12-18 octubre

SECCIÓN: 1

GRUPO: 171

CARRERA: Tecnologías de la Información e Innovación Digital

MATRÍCULA: 24305019

FECHA DE ENTREGA: 18 de octubre de 2026

1. PLANTEAMIENTO Y FORMULACIÓN DEL PROBLEMA

La Inteligencia Artificial ha pasado de ser una promesa teórica a una herramienta con impacto medible en sectores críticos de la sociedad. Sin embargo, la literatura académica y los reportes mediáticos frecuentemente presentan casos sin evidencia verificable de resultados cuantificables, lo que dificulta la evaluación objetiva de su valor real.

Problema a resolver: Seleccionar, analizar y comparar tres casos reales de aplicación de IA en los sectores de salud, industria y movilidad, identificando de forma rigurosa: (a) el problema específico resuelto, (b) las técnicas de IA empleadas, (c) el impacto medible con indicadores clave de desempeño (KPI), y (d) las fuentes verificables que respaldan los resultados.

Este análisis permite comprender cómo las metodologías de IA (aprendizaje supervisado, redes neuronales convolucionales, optimización combinatoria y detección de anomalías) se traducen en soluciones concretas con retorno de inversión demostrable y beneficios sociales o ambientales cuantificables.

2. OBJETIVOS

Objetivo general: Elaborar un informe comparativo de tres casos reales de aplicación de Inteligencia Artificial en salud, industria y movilidad, documentando técnicas, impacto medible y fuentes verificables.

Objetivos específicos:

- Describir cada caso incluyendo contexto, problema resuelto y técnica de IA utilizada.
- Cuantificar el impacto mediante KPI reportados en fuentes primarias o estudios revisados.
- Construir una tabla comparativa con criterios: rama de IA, técnica, sector, KPI y país.
- Elaborar una infografía comparativa visual de los tres casos.
- Extraer conclusiones reflexivas sobre el valor y las limitaciones de estas implementaciones.

3. PROCEDIMIENTO METODOLÓGICO

Se realizó una búsqueda sistemática de casos de uso reales publicados entre 2016 y 2026 en fuentes académicas (Nature, revistas de radiología, arXiv), reportes corporativos verificables (UPS, Siemens) y estudios clínicos prospectivos/retrospectivos. Se priorizaron casos con: (1) impacto cuantificado, (2) técnica de IA claramente identificable, y (3) fuente primaria o peer-reviewed. Cada caso

se estructuró siguiendo el formato: descripción, problema, técnica, impacto y fuente. El marco conceptual de las ramas de la IA se tomó de García Serrano (2016, cap. 1) y Russell y Norvig (2020, cap. 1).

Datos del problema. Los datos analizados son tres casos reales, uno por sector (salud, industria y movilidad), con sus indicadores clave de desempeño (KPI) tomados de artículos revisados por pares y reportes oficiales de las empresas. No se generaron datos propios; por tratarse de una investigación documental, esta actividad no incluye código.

4. CASOS DE ESTUDIO SELECCIONADOS (SOLUCIÓN Y RESULTADOS)

1. **Caso de Salud:** Google AI para Detección de Cáncer de Mama (NHS, Reino Unido)

Descripción del caso: Google Health desarrolló un sistema de inteligencia artificial (versión 1.2) basado en redes neuronales profundas para la interpretación de mamografías de cribado poblacional. El sistema fue evaluado en el mayor estudio de este tipo realizado hasta la fecha dentro de National Health Service (NHS) del Reino Unido (Kelly et al., 2026).

Comprendió una fase retrospectiva con 115,973 mamografías de cinco servicios de screening (mujeres de 50-70 años, con seguimiento de 39 meses) y un despliegue prospectivo de viabilidad técnica no intervencionista en 12 sitios clínicos (9,266 casos). El sistema analiza las cuatro proyecciones estándar de mamografía digital de campo completo y devuelve una decisión a nivel de caso y de mama, junto con regiones de interés (ROI) sospechosas.

Problema resuelto: El cribado de cáncer de mama mediante doble lectura humana (estándar en el Reino Unido y gran parte de Europa) enfrenta tres limitaciones estructurales críticas:

1. Escasez de radiólogos y carga de trabajo elevada: Cada mamografía debe ser leída por al menos dos radiólogos independientes. La falta de personal genera retrasos, backlog y fatiga del lector, lo que incrementa el riesgo de errores.
2. Variabilidad interobservador y cánceres de intervalo: Existe un porcentaje no despreciable de cánceres que se manifiestan entre dos rondas de screening (cánceres de intervalo). Estos suelen tener signos sutiles en la mamografía previa que el ojo humano no siempre detecta. Estudios previos mostraban que una proporción importante de estos cánceres tiene hallazgos visibles en retrospectiva.

3. Necesidad de mantener alta especificidad: Cualquier sistema de apoyo debe evitar aumentar las tasas de recuerdo (falsos positivos), porque generan ansiedad, costos adicionales y procedimientos invasivos innecesarios.

El objetivo del proyecto era demostrar que la IA puede igualar o superar la sensibilidad del primer lector humano sin degradar la especificidad, detectar una proporción significativa de cánceres de intervalo y reducir la carga de trabajo de lectura cuando se utiliza como segundo lector.

Técnicas empleadas: El sistema pertenece a la rama de **Visión por Computadora y Aprendizaje Profundo Supervisado.** Utiliza arquitecturas de redes neuronales convolucionales (CNN) actualizadas respecto a la versión 1.0 previamente publicada. Las características técnicas principales son:

- Entrada multimodal: Procesa las cuatro imágenes estándar de mamografía digital (craneocaudal y oblicua mediolateral de ambas mamas)
- Salida Estructurada: Genera decisión a nivel de caso (positivo/negativo), decisión a nivel de mama y mapas de regiones de interés (ROI) con puntuaciones de sospecha
- Entrenamiento: Modelos entrenados con grandes volúmenes de mamografías anotadas, utilizando como ground truth cánceres detectados en el screening como cánceres de intervalo y de la siguiente ronda (seguimiento de 39 meses)
- Modo de uso clínico: Puede operar como lector independiente (standalone) o como segundo lector dentro del flujo de doble lectura británico, enviando casos discordantes a un panel de arbitraje humano.
- Umbral operativo (Operating Point): Se calibra para equilibrar sensibilidad y especificidad según los requisitos del programa de screening.

Impacto medible: Los resultados se publicaron en un artículo de Nature Cancer (marzo 2026; Kelly et al., 2026). Los KPI más relevantes del estudio retrospectivo (115,973 mamografías) son:

- Sensibilidad superior al primer lector humano: 0,541 vs 0,437 ($p < 0,001$). La IA detectó más cánceres sin comprometer de forma significativa la especificidad (0,943 vs 0,952, no inferior).
- Tasa de detección de cáncer (CDR): Aumento de 7,54 a 9,33 por 1.000 mujeres (+23,7 %).
- Cánceres de intervalo: La IA identificó correctamente el 25,0 % (IC 95 %: 20,4–30,0 %) de los cánceres de intervalo futuros. El 88 % de estos se localizaron en la mama correcta y el 58,1 % en la lesión precisa.
- Cánceres de la siguiente ronda: Detectó el 25,1 % de los cánceres que solo se diagnosticarían tres años después en el siguiente screening asintomático.

- Rendimiento en primeras mamografías (prevalent screens): 39,3 % menos recuerdos y 8,8 % mayor tasa de detección respecto al primer lector humano. Especialmente fuerte en cánceres invasivos.
- Reducción de carga de trabajo: Cuando la IA actúa como segundo lector, se estima una reducción del 32,1 % en el tiempo total de lectura humana (y hasta ~40 % en análisis de Google).
- Equidad: No se observaron disparidades demográficas sistemáticas en el rendimiento del modelo. En el estudio de flujo de trabajo (IA como segundo lector + arbitraje), la sensibilidad y especificidad del brazo con IA fueron estadísticamente no inferiores al brazo de doble lectura humana tradicional.

2. Caso Industria: Siemens Senseye Predictive Maintenance

Descripción del caso: Senseye Predictive Maintenance es una plataforma de Siemens Digital Industries que aplica inteligencia artificial al mantenimiento de activos industriales. Analiza de forma continua datos de sensores (vibración, temperatura, presión, consumo eléctrico, velocidad, etc.) procedentes de equipos de producción para anticipar fallos antes de que ocurran. Ha sido desplegada en sectores tan diversos como la industria acerera (BlueScope, Australia), alimentaria (Sachsenmilch, Alemania), aluminio, automotriz y manufactura discreta. En algunos clientes se monitorizan más de 10.000 máquinas de más de 100 tipos diferentes de forma remota (Siemens, s. f.-c).

Problema resuelto: Las plantas industriales tradicionales operan bajo dos paradigmas de mantenimiento limitados:

1. **Mantenimiento reactivo (run-to-failure):** Se interviene solo cuando el equipo falla. Genera paradas no planificadas de alto costo (un minuto de downtime en líneas críticas puede costar decenas de miles de dólares), riesgos de seguridad y daños colaterales a otros componentes.
2. **Mantenimiento preventivo basado en tiempo o en horas de operación:** Se programan intervenciones periódicas independientemente del estado real del activo. Esto provoca tanto sobremantenimiento (costos innecesarios de mano de obra y repuestos) como sub-mantenimiento (fallos entre intervalos).

El problema central es la falta de visibilidad del estado real de degradación de los activos. Sin datos y sin modelos que conviertan esos datos en predicciones accionables, las decisiones de mantenimiento se basan en experiencia humana o en reglas fijas, lo que limita la disponibilidad (OEE) y eleva los costos operativos. El objetivo de Senseye es transformar el mantenimiento en un proceso predictivo basado en condición, permitiendo planificar intervenciones en ventanas programadas y evitar paradas críticas.

Técnicas empleadas: La solución se enmarca en la rama de Aprendizaje Automático / Detección de Anomalías / Pronóstico Predictivo. Combina varias familias de técnicas:

- **Detección de anomalías:** Modelos no supervisados o semi-supervisados que aprenden el comportamiento "normal" de cada activo a partir de series temporales de sensores y detectan desviaciones sutiles (cambios en vibración RMS, temperatura, presión, consumo energético).
- **Pronóstico de degradación y Remaining Useful Life (RUL):** Modelos de machine learning que estiman la vida útil restante de componentes críticos (bombas, rodamientos, motores, etc.) y generan alertas con semanas o meses de anticipación.
- **Ajuste automático (auto-tuning):** Capacidad de adaptar los umbrales y modelos a cada tipo de máquina sin necesidad de una ingeniería de características exhaustiva por parte del usuario.
- **Interfaz generativa reciente (Maintenance Copilot):** En 2025 se incorporó un asistente basado en IA generativa que permite consultar el estado de los activos en lenguaje natural ("¿Qué soldadoras tienen riesgo alto en las próximas dos semanas?") (Siemens, 2025b).
- **Integración con sistemas de planta:** Conexión con SCADA, IoT industrial, SAP Plant Maintenance y plataformas de Edge computing de Siemens para cerrar el ciclo desde la predicción hasta la orden de trabajo.

Impacto medible: Los resultados reportados por Siemens a partir de implementaciones reales incluyen:

- **Reducción del tiempo de mantenimiento reactivo:** En pilotos tempranos, el Maintenance Copilot de Siemens redujo en promedio 25 % el tiempo de mantenimiento reactivo (Siemens, 2025b).
- **Caso BlueScope (acero, Australia y otros países):** Más de 1.950 horas de downtime evitadas en múltiples ubicaciones, 53 paradas de proceso evitadas y, en un solo evento de fuga hidráulica, al menos 24 horas de parada no planificada evitadas en una línea de revestimiento metálico (Siemens, s. f.-b).
- **Caso Sachsenmilch (lácteos, Alemania):** Detección anticipada del final de vida útil de una bomba crítica, permitiendo su reemplazo en una parada programada y evitando una falla en producción. Ahorro documentado de seis cifras bajas en ese único evento (Siemens, 2025a).
- **Fabricante automotriz global:** Decenas de millones de dólares en downtime ahorrado; ROI en menos de 3 meses; detección de fallos con meses de anticipación; más de 10.000 máquinas monitorizadas (Siemens, s. f.-a).

3. Caso Movilidad: UPS ORION (On-Road Integrated Optimization and Navigation)

Descripción del caso: ORION es el sistema de optimización de rutas de UPS, considerado uno de los proyectos de investigación de operaciones más grandes del mundo aplicados a la industria. Determina diariamente la secuencia óptima de paradas para más de 55.000 conductores en Estados Unidos. El sistema considera restricciones de ventanas de tiempo de servicio, capacidad del vehículo, preferencias operativas (por ejemplo, minimizar giros a la izquierda), datos de tráfico y pedidos en tiempo real. Evolucionó desde una versión estática (plan del día) hasta versiones dinámicas (ORION 2.0 / 3.0) que reoptimizan la ruta a lo largo del día conforme cambian las condiciones (Holland et al., 2017).

Problema resuelto: La planificación de rutas de entrega es un problema clásico de optimización combinatoria (Vehicle Routing Problem con ventanas de tiempo y restricciones de capacidad). Antes de ORION, UPS enfrentaba:

1. Ineficiencia acumulada a gran escala: Incluso pequeñas ineficiencias diarias (pocas millas extra por conductor) se multiplican por decenas de miles de rutas y producen cientos de millones de dólares en costos innecesarios de combustible, mantenimiento de vehículos y tiempo de conductores.
2. Limitaciones de la planificación manual o semiautomática: Los despachadores humanos no pueden evaluar los cientos de miles de combinaciones posibles de secuencia de paradas que existen para un solo día de un conductor típico (alrededor de 120 paradas).
3. Dinamismo del entorno: Tráfico, cancelaciones, nuevas recogidas, fallos de entrega y preferencias de clientes cambian a lo largo del día. Un plan fijo generado por la mañana pierde rápidamente optimalidad.
4. Objetivos múltiples y a veces conflictivos: Minimizar distancia y tiempo, respetar ventanas de entrega premium (Next Day Air), maximizar densidad de entregas, reducir emisiones y mejorar la seguridad (por ejemplo, evitando giros a la izquierda en intersecciones peligrosas).

El objetivo de ORION era generar de forma automática, cada día y para cada conductor, una secuencia de paradas que minimizara el costo operativo total bajo todas estas restricciones, y posteriormente permitir la Reoptimización dinámica intradía.

Técnicas empleadas: ORION se enmarca en la rama de Optimización Combinatoria / Investigación de Operaciones + Aprendizaje Automático. Sus componentes técnicos principales son:

- Formulación como Vehicle Routing Problem (VRP) con ventanas de tiempo: Variante del problema del viajante (TSP) con restricciones de capacidad, ventanas de servicio y múltiples objetivos.
- Metaheurísticas y heurísticas avanzadas: Dado que el VRP es NP-duro, se utilizan algoritmos de búsqueda local, metaheurísticas y técnicas de

descomposición para explorar el espacio de soluciones de forma eficiente. El sistema evalúa hasta 200.000 opciones de ruta por conductor al día.

- Machine Learning para predicción de tiempos: Modelos que predicen tiempos de viaje y de servicio en cada parada a partir de datos históricos, patrones de tráfico, tipo de cliente y características del paquete.
- Políticas operativas codificadas: Preferencia por giros a la derecha (para reducir idling y riesgo de accidentes), priorización de entregas premium y reglas de seguridad.
- Reoptimización dinámica (ORION 2.0 / 3.0): Versión en la nube que recibe actualizaciones continuas desde el dispositivo DIAD del conductor y replanifica la secuencia restante de paradas cuando aparecen nuevas recogidas, cambios de tráfico o fallos de entrega.
- Bucle de retroalimentación: Comparación continua entre el plan generado y la ejecución real para mejorar mapas, tiempos estimados y reglas.

Impacto medible: Los resultados reportados por UPS (y consistentes a lo largo de múltiples fuentes de la industria; Holland et al., 2017) son:

- Millas ahorradas: Más de 100 millones de millas anuales en la fase de despliegue completo (algunas fuentes actualizadas reportan más de 130 millones). Equivale a una reducción promedio de 6-8 millas por conductor por día en la versión original.
- Ahorro de combustible: Aproximadamente 10 millones de galones de combustible al año.
- Reducción de emisiones: Alrededor de 100.000 toneladas métricas de CO_2 evitadas anualmente.
- Ahorro económico: Entre 300 y 400 millones de dólares anuales en costos combinados de combustible y vehículos. Cada milla eliminada por conductor por día se estima en aproximadamente 50 millones de dólares de ahorro anual para la flota completa.
- Versión dinámica: ORION 2.0/3.0 añade entre 2 y 4 millas adicionales de ahorro por conductor por día al reoptimizar durante la jornada.
- ROI del proyecto: Inversión inicial del orden de 250-295 millones de dólares; para finales de 2015 ya había generado más de 320 millones de dólares en ahorros, superando las proyecciones originales y acelerando el despliegue nacional.
- Impacto en seguridad y servicio: La política de minimizar giros a la izquierda reduce el tiempo de idling y el riesgo de accidentes en intersecciones. La reoptimización dinámica mejora la precisión de las ventanas de entrega comunicadas al cliente.

5. TABLA COMPARATIVA DE CRITERIOS

La siguiente tabla sintetiza los tres casos según los criterios solicitados: rama de IA, técnica específica, sector, indicador clave de desempeño (KPI) principal y país de implementación principal.

CRITERIO	CASO 1- SALUD	CASO 2- INDUSTRIA	CASO 3- MOVILIDAD
Rama de IA	Visión por Computadora / Deep Learning	Aprendizaje Automático / Detección de Anomalías	Optimización Combinatoria/ Investigación de operaciones (con heurísticas)
Técnica principal	Redes neuronales convolucionales (CNN) sobre las cuatro proyecciones de mamografía, con regiones de interés (ROI)	Detección de anomalías en series de tiempo de sensores + estimación de vida útil restante (RUL)	Problema de ruteo de vehículos (VRP) con restricciones, resuelto con heurísticas y datos de operación
Sector	Salud	Industria manufacturera	Logística y Transporte
KPI principal	Sensibilidad 0.541 vs 0.437 del primer lector humano ($p < 0.001$); especificidad 0.943 vs 0.952 (no inferior); tasa de detección 7.54 →9.33 por 1,000 mujeres (+23.7%)	Fabricante automotriz global: más de 10,000 máquinas monitoreadas, retorno de inversión en menos de 3 meses, aviso de fallas con meses de anticipación y decenas de millones en paros evitados. Sachsenmilch: ahorro de seis cifras bajas por detectar a tiempo una bomba defectuosa	100 millones de millas menos por año; 10 millones de galones de combustible; 100,000 t de CO_2 evitadas, ahorro de 300-400 millones de USD al año con el despliegue completo (55,000 conductores)
País / Región	Reino Unido (NHS)	Alemania (Siemens)/clientes a nivel Global	Estados Unidos
Fuente clave	Kelly et al. (2026), Nature Cancer	Siemens (s. f.-a), caso de estudio automotriz de Senseye	Holland et al. (2017), Interfaces, 47

Tabla 1. Comparación de los tres casos. Elaboración propia

6. INFOGRAFÍA COMPARATIVA

La siguiente infografía resume visualmente los tres casos seleccionados, destacando sector, técnica de IA principal, país e indicadores de impacto más relevantes (Imagen 1, elaboración propia).

7. CONCLUSIÓN



Imagen 1. Inteligencia artificial: 3 casos reales. Elaboración propia.

Existen implementaciones reales de IA con impacto medible y verificable en salud, industria y movilidad. Los tres casos seleccionados demuestran retornos claros en precisión diagnóstica, disponibilidad de equipos y eficiencia logística.

Las técnicas predominantes siguen siendo el aprendizaje profundo supervisado (visión), la detección de anomalías y el pronóstico predictivo, y la optimización combinatoria asistida por aprendizaje automático. La IA generativa aún no es el motor principal de estos casos de alto impacto.

El valor de la IA se maximiza cuando se integra en el flujo de trabajo existente (segundo lector, mantenimiento basado en condición, reoptimización dinámica de rutas) y no cuando se despliega como sistema aislado.

La medición rigurosa de KPI (tasa de detección, downtime, millas, CO2, costos) es indispensable para distinguir implementaciones exitosas de proyectos que no generan retorno medible.

Desde la perspectiva ética y de reproducibilidad, todos los casos se benefician de validación externa (estudios peer-reviewed en salud; métricas públicas y consistentes en industria y logística). Futuros trabajos deberían exigir mayor transparencia en los conjuntos de datos y en los protocolos de evaluación post-despliegue.

Limitaciones. En el caso de salud, el estudio principal es retrospectivo y la fase prospectiva fue solo de factibilidad técnica (2 sitios, unas 8 semanas): el umbral operativo inicial generó demasiadas citaciones para nueva revisión y tuvo que recalibrarse localmente, y la tasa de recuerdo del sistema fue mayor que la del primer lector humano (6,5 % vs 5,5 %). Además, el sistema aún no está disponible para uso externo (Kelly et al., 2026). En industria y logística, las cifras provienen de reportes de las propias empresas (Siemens, s. f.-a, s. f.-b, 2025; Holland et al., 2017), no de auditorías independientes, y dependen del contexto de cada cliente, por lo que no deben generalizarse sin validación propia.

8. REFERENCIAS

García Serrano, A. (2016). Inteligencia artificial: Fundamentos, práctica y aplicaciones (2.ª ed.). RC Libros.

Holland, C., Levis, J., Nuggehalli, R., Santilli, B., & Winters, J. (2017). UPS optimizes delivery routes. Interfaces, 47(1), 8–23. https://doi.org/10.1287/inte.2016.0875

Kelly, C. J., Wilson, M., Warren, L. M., Sidebottom, R., Halling-Brown, M., Yang, L., Morigami, M., Venton, J., Chopra, R., Chang, J., Dixon, J., Gilbert, F. J., Golden, D. I., Gruzewska, E., Honeyfield, L., Hujan, A., Khodabakhshi, D., Lewis, E., Malhotra, N., . . . Cunningham, D. (2026). Diagnostic accuracy, fairness and clinical implementation of AI for breast cancer screening: Results of multicenter retrospective and prospective technical feasibility studies. *Nature Cancer,* 7(3), 494–506. https://doi.org/10.1038/s43018-026-01127-0

Russell, S., & Norvig, P. (2020). Inteligencia artificial: Un enfoque moderno (4.ª ed.). Pearson.

Siemens. (s. f.-a). *How a global automotive manufacturer reduced downtime and improved OEE with predictive maintenance* [Folleto]. https://resources.sw.siemens.com/en-US/brochure-senseye-predictive-maintenance-increases-oee/

Siemens. (s. f.-b). *BlueScope benefits from AI-supported maintenance*. https://www.siemens.com/en-us/company/insights/bluescope-predictive-maintenance/

Siemens. (s. f.-c). *Predictive maintenance at scale | Senseye cloud application*. https://www.siemens.com/global/en/products/services/digital-enterprise-services/analytics-artificial-intelligence-services/senseye-predictive-maintenance/industry-specific-solutions.html

Siemens. (2025a, 4 de junio). *AI-supported predictive maintenance: Siemens and Sachsenmilch are breaking new ground in the food and beverage industry* [Comunicado de prensa]. https://press.siemens.com/global/en/pressrelease/siemens-advances-predictive-maintenance-artificial-intelligence-sachsenmilch

Siemens. (2025b, 24 de marzo). *Siemens expands Industrial Copilot with new generative AI-powered maintenance offering* [Comunicado de prensa]. https://press.siemens.com/global/en/pressrelease/siemens-expands-industrial-copilot-new-generative-ai-powered-maintenance-offering

DECLARACIÓN DE USO DE INTELIGENCIA ARTIFICIAL

Herramienta utilizada: Grok (xAI) y Claude (Anthropic)

Propósito: Apoyo en la búsqueda y estructuración de información de casos reales a partir de fuentes web y académicas. Claude: revisión ortográfica, verificación de fuentes y formato de referencias APA 7.

Prompt utilizado: Seleccionar tres casos reales de aplicación de IA en salud, industria y movilidad. Describir el problema resuelto, las técnicas empleadas, el impacto medible y las fuentes verificables. Prompt a Claude: «Revisa si mi documento cumple los requisitos de la actividad, corrige errores de ortografía y ajusta las referencias a APA 7 con enlaces.»

Verificación: Se contrastaron las cifras principales con las fuentes originales enlazadas en las referencias (sensibilidad, tasa de detección, cánceres de intervalo y reducción de carga de lectura; horas de downtime y paradas evitadas; ahorro de combustible, CO2 y costos) y se corrigieron errores de ortografía, citas y referencias.